

Proof of formula in *Gaussian Process Regression with Censored Data Using Expectation Propagation*, Groot, Lucas [GL12]

12 octobre 2021

1 Formula (14)

1.1 Expression de \hat{Z}_i

\hat{Z}_i est défini par

$$\hat{Z}_i = \int q_{\setminus i} t_i df_i \quad (1)$$

avec $q_{\setminus i} = \mathcal{N}(\mu_{\setminus i}, \sigma_{\setminus i}^2)$ et $t_i = p(y_i | f_i)$.

Dans le cas $y_i = l$, on a

$$p(y_i = l | f_i) = 1 - \Phi\left(\frac{f_i - l}{\sigma}\right) \quad (2)$$

où Φ est la fonction de répartition de la loi normal centrée réduite.

On a alors

$$\hat{Z}_i = \int \left(1 - \Phi\left(\frac{f_i - l}{\sigma}\right)\right) \mathcal{N}(f_i; \mu_{\setminus i}, \sigma_{\setminus i}^2) df_i \quad (3)$$

$$= 1 - \int \Phi\left(\frac{f_i - l}{\sigma}\right) \mathcal{N}(f_i; \mu_{\setminus i}, \sigma_{\setminus i}^2) df_i \quad (4)$$

$$= 1 - E_{q_{\setminus i}}\left(\Phi\left(\frac{f_i - l}{\sigma}\right)\right) \quad (5)$$

$$= 1 - E_{q_{\setminus i}}\left(P\left(X \leq \frac{f_i - l}{\sigma}\right)\right) \quad (6)$$

où X est une VA suivant une loi normale centrée réduite. X et f_i étant des VA indépendantes, on a alors simplement

$$\hat{Z}_i = 1 - P\left(X \leq \frac{f_i - l}{\sigma}\right) \quad (7)$$

$$= 1 - P\left(X - \frac{f_i}{\sigma} \leq \frac{-l}{\sigma}\right) \quad (8)$$

$$= 1 - P\left(Z \leq \frac{-l}{\sigma}\right) \quad (9)$$

où $Z = X - \frac{f_i}{\sigma} \sim \mathcal{N}\left(\frac{-\mu_{\setminus i}}{\sigma}, 1 + \frac{\sigma_{\setminus i}^2}{\sigma^2}\right)$. On en déduit, avec Z' une loi normale centrée réduite telle que

$$Z = \frac{-\mu_{\lambda_i}}{\sigma} + \sqrt{1 + \frac{\sigma_{\lambda_i}^2}{\sigma^2}} Z',$$

$$\hat{Z}_i = 1 - P \left(Z' \leq \frac{\mu_{\lambda_i} - l}{\sigma \sqrt{1 + \frac{\sigma_{\lambda_i}^2}{\sigma^2}}} \right) \quad (10)$$

$$= 1 - P \left(Z' \leq \frac{\mu_{\lambda_i} - l}{\sqrt{\sigma^2 + \sigma_{\lambda_i}^2}} \right) \quad (11)$$

$$= 1 - \Phi \left(\frac{\mu_{\lambda_i} - l}{\sqrt{\sigma^2 + \sigma_{\lambda_i}^2}} \right) \quad (12)$$

2 Moyenne de la prédiction $p(y|\mathcal{D})$

La formule n'est pas présente dans le papier mais dans le code source Matlab à la fonction *lik_tobit1_predy*. Seule la moyenne est donnée par

$$\begin{aligned} E(y|\mathcal{D}) &= \left(\Phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) - \Phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) \right) \left(\mu_f + \sqrt{\sigma^2 + \sigma_f^2} \frac{\phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) - \phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right)}{\Phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) - \Phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right)} \right) \\ &\quad + l \Phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) \mathbb{1}_{l > -\infty} + u \left(1 - \Phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) \right) \mathbb{1}_{u < +\infty} \end{aligned} \quad (13)$$

Démonstration. Tout d'abord, pour simplifier l'écriture on pose :

$$a = \frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}}, \quad b = \frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}}, \quad s = \sqrt{\sigma^2 + \sigma_f^2} \quad (14)$$

$$\Phi_a = \Phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right), \quad \phi_a = \phi \left(\frac{l - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) \quad (15)$$

$$\Phi_b = \Phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right), \quad \phi_b = \phi \left(\frac{u - \mu_f}{\sqrt{\sigma^2 + \sigma_f^2}} \right) \quad (16)$$

On a

$$p(y|\mathcal{D}) = \int p(y|f, \mathcal{D}) p(f|\mathcal{D}) df \quad (17)$$

L'espérance est donc donnée par les trois termes de la vraisemblance Tobit

$$E(y|\mathcal{D}) = l p(y = l|\mathcal{D}) + u p(y = u|\mathcal{D}) + \int_{y=l}^u y p(y|\mathcal{D}) dy \quad (18)$$

$$\begin{aligned} &= l \int_f p(y = l|f, \mathcal{D}) p(f|\mathcal{D}) df + u \int_f p(y = u|f, \mathcal{D}) p(f|\mathcal{D}) df \\ &\quad + \int_{y=l}^u y \int_f p(y|f, \mathcal{D}) p(f|\mathcal{D}) df dy \end{aligned} \quad (19)$$

Pour le premier terme, on a en utilisant la même technique qu'à la section précédente pour le calcul de \hat{Z}_i

$$l \int_f p(y = l|f, \mathcal{D}) p(f|\mathcal{D}) df = l \int_f \left(1 - \Phi \left(\frac{f - l}{\sigma} \right) \right) p(f|\mathcal{D}) df \quad (20)$$

$$= l \Phi_a \quad (21)$$

De même, on a :

$$u \int_f p(y = u|f, \mathcal{D}) p(f|\mathcal{D}) df = u (1 - \Phi_b) \quad (22)$$

Pour le dernier terme, on utilise la formule sur le produit de deux pdf gaussiennes :

$$\int_{y=l}^u y \int_f p(y|f, \mathcal{D}) p(f|\mathcal{D}) df dy = \int_{y=l}^u y \mathcal{N}(y|\mu_f, \sigma^2 + \sigma_f^2) dy \quad (23)$$

$$= \int_{y=l}^u \frac{y}{s} \phi\left(\frac{y - \mu_f}{s}\right) dy \quad (24)$$

$$= \int_{y=a}^b (sy + \mu_f) \phi(y) dy \quad (25)$$

$$= \mu_f (\Phi_b - \Phi_a) + s \int_{y=a}^b y \phi(y) dy \quad (26)$$

Sachant que la primitive de Φ est donnée par $\int \Phi(x) dx = x\Phi(x) + \phi(x) + C$, on a par IPP

$$\int_{y=a}^b y \phi(y) dy = [y\Phi(y)]_a^b - \int_a^b \Phi(y) dy \quad (27)$$

$$= b\Phi_b - a\Phi_a - (b\Phi_b - a\Phi_a + \phi_a - \phi_b) \quad (28)$$

$$= \phi_a - \phi_b \quad (29)$$

ce qui donne

$$\int_{y=l}^u y \int_f p(y|f, \mathcal{D}) p(f|\mathcal{D}) df dy = \mu_f (\Phi_b - \Phi_a) + s (\phi_a - \phi_b) \quad (30)$$

On obtient donc le résultat final

$$E(y|\mathcal{D}) = l\Phi_a + u(1 - \Phi_b) + \mu_f (\Phi_b - \Phi_a) + s (\phi_a - \phi_b) \quad (31)$$

□

3 Variance de la prédiction $p(y|\mathcal{D})$

La variance de la prédiction n'est pas implémentée dans le code source du papier mais est facilement calculable. En reprenant les même calculs que précédemment, on obtient

$$Var(Y|\mathcal{D}) = E(Y^2|\mathcal{D}) - E(Y|\mathcal{D})^2 \quad (32)$$

Le deuxième terme est directement obtenu à la section précédente. Pour le premier terme, on calcule

$$\int_a^b y^2 \phi(y) dy = [y^2 \Phi(y)]_a^b - 2 \int_a^b y \Phi(y) dy \quad (33)$$

et avec encore une IPP

$$\int_a^b y \Phi(y) dy = \frac{1}{2} (b(b\Phi_b + \phi_b) - a(a\Phi_a + \phi_a)) \quad (34)$$

On obtient finalement

$$E(Y^2|\mathcal{D}) = l^2\Phi_a + u^2(1 - \Phi_b) + \mu_f^2 (\Phi_b - \Phi_a) + s^2 (a\phi_a + \Phi_a - b\phi_b - \Phi_b) + 2s\mu_f (\phi_a - \phi_b) \quad (35)$$

4 Dérivée seconde de la log-vraisemblance

La dérivée seconde de la log-vraisemblance se calcule facilement et le résultat est donné par

$$\frac{\partial^2 \log L}{\partial f_i^2} = \frac{1}{\sigma^2} \left[\phi(z_l) \frac{z_l (1 - \Phi(z_l)) - \phi(z_l)}{(1 - \Phi(z_l))^2} \mathbf{1}_{[y_i=l]} - \phi(z_u) \frac{z_u \Phi(z_u) + \phi(z_u)}{\Phi(z_u)^2} \mathbf{1}_{[y_i=u]} - \mathbf{1}_{[l < y_i < u]} \right] \quad (36)$$

avec $z_l = \frac{f_i - l}{\sigma}$, $z_u = \frac{f_i - u}{\sigma}$. Afin d'exploiter l'approximation du ratio $\frac{\phi}{\Phi}$ pour des petites valeurs de z donnée dans [GL] par

$$\frac{\phi(z)}{\Phi(z)} \sim \sqrt{\frac{1}{4}z^2 + 1} - \frac{1}{2}z \quad (37)$$

et en exploitant le fait que [GL12]

$$\frac{\phi(z)}{1 - \Phi(z)} = \frac{\phi(-z)}{\Phi(-z)} \quad (38)$$

on peut réécrire la dérivée seconde comme suit

$$\frac{\partial^2 \log L}{\partial f_i^2} = \frac{1}{\sigma^2} \left[\frac{\phi(-z_l)}{\Phi(-z_l)} \left(z_l - \frac{\phi(-z_l)}{\Phi(-z_l)} \right) \mathbf{1}_{[y_i=l]} - \frac{\phi(z_u)}{\Phi(z_u)} \left(z_u + \frac{\phi(z_u)}{\Phi(z_u)} \right) \mathbf{1}_{[y_i=u]} - \mathbf{1}_{[l < y_i < u]} \right] \quad (39)$$

Références

- [GL] Perry Groot and Peter Lucas. Supplementary material for ‘gaussian process regression with censored data using expectation propagation’.
- [GL12] Perry Groot and Peter JF Lucas. Gaussian process regression with censored data using expectation propagation. 2012.